



Machine learning

Dự đoán nguy cơ mắc bệnh tiểu đường (LR, RF)

Sinh viên trình bày: Phạm Tùng Dương

Giảng viên hướng dẫn: PGS.TS: Nguyễn Văn Hậu

Table of Contents

- 1 **Tổng quan bài toán**
- 2 **Mô hình học máy**
- 3 **Triển khai mô hình**
- 4 **Demo chương trình**

Tổng quan bài toán

Thực tế việc dự báo sớm nguy cơ mắc bệnh tiểu đường là một trong những nhiệm vụ quan trọng nhất của y học hiện đại.

Việc phát hiện sớm giúp:


- Giảm tới 50–70% khả năng lâm trọng bệnh
- Tiết kiệm hàng tỷ đô chi phí điều trị biến chứng
- Cứu sống và nâng cao chất lượng cuộc sống cho hàng triệu người mỗi năm

Bài toán Diabetes Risk Prediction là bài toán **Binary Classification** nhằm dự đoán xem một người có khả năng mắc bệnh tiểu đường hay không.



Mô hình học máy

Các mô hình được sử dụng trong bài toán:



Logistic Regression




Random Forest

Logistic Regression

Logistic Regression là một thuật toán học máy có giám sát (supervised learning) dùng để dự đoán xác suất của một biến mục tiêu dạng nhị phân (binary), tức là đầu ra chỉ có hai giá trị như:

- 1/0
- Có bệnh / không bệnh
- Spam / không spam
- Chấp nhận / từ chối




Random Forest

Random Forest là một thuật toán học máy có giám sát (supervised learning) thuộc nhóm ensemble learning. Nó hoạt động bằng cách kết hợp nhiều cây quyết định (Decision Trees) để tạo ra một mô hình mạnh hơn, ổn định hơn và chính xác hơn.

- Phân loại (classification): các cây bỏ phiếu, lớp nào nhiều phiếu hơn → kết quả.
- Hồi quy (regression): lấy trung bình của kết quả từ các cây.

Random Forest



Các Metric đánh giá mô hình

- Accuracy
- Precision
- Recall
- F1 - score



Triển khai mô hình

Mô tả dữ liệu:


	age	gender	pulse_rate	systolic_bp	diastolic_bp	glucose	height	weight	bmi	family_diabetes	hypertensive	family_hypertension	cardiovascular_disease	stroke	diabetic
0	42	Female	66	110	73	5.88	1.65	70.2	25.75	0	0	0	0	0	No
1	35	Female	60	125	68	5.71	1.47	42.5	19.58	0	0	0	0	0	No
2	62	Female	57	127	74	6.85	1.52	47.0	20.24	0	0	0	0	0	No
3	73	Male	55	193	112	6.28	1.63	57.4	21.72	0	0	0	0	0	No
4	68	Female	71	150	81	5.71	1.42	36.0	17.79	0	0	0	0	0	No

	age	gender	pulse_rate	systolic_bp	diastolic_bp	glucose	height	weight	bmi	family_diabetes	hypertensive	family_hypertension	cardiovascular_disease	stroke	diabetic
5283	74	Male	83	164	89	6.47	1.60	64.0	24.99	0	1	0	1	0	No
5284	75	Male	67	141	104	8.31	1.65	62.0	22.75	0	0	0	0	0	Yes
5285	40	Female	67	134	114	7.61	1.50	69.0	30.72	0	1	0	0	1	No
5286	36	Female	62	139	80	4.90	1.52	41.5	17.87	0	0	0	0	0	No
5287	26	Female	80	134	93	5.15	1.47	67.1	30.92	0	0	0	0	0	No




Phân tích dữ liệu

Phân bố Glucose - Yếu tố QUYẾT ĐỊNH tiểu đường



TỶ LỆ MẮC BỆNH TIỂU ĐƯỜNG THEO GIỚI TÍNH




Phân tích dữ liệu

...

▲


TỶ LỆ MẮC BỆNH TIỂU ĐƯỜNG THEO NHÓM TUỔI






Phân tích dữ liệu

TỶ LỆ MẮC BỆNH TIỂU ĐƯỜNG THEO TIỀN SỬ GIA ĐÌNH




TỶ LỆ MẮC BỆNH TIỂU ĐƯỜNG THEO TIỀN SỬ ĐỘT QUY






Phân tích dữ liệu

TỶ LỆ MẮC BỆNH TIỂU ĐƯỜNG THEO MỨC ĐƯỜNG HUYẾT




TỶ LỆ MẮC BỆNH TIỂU ĐƯỜNG THEO NHÓM CHỈ SỐ BMI
(Càng béo → nguy cơ càng cao)





Phân tích dữ liệu

TOP 10 YẾU TỐ QUAN TRỌNG NHẤT DỰ ĐOÁN BỆNH TIỂU ĐƯỜNG
(theo Random Forest)




Phân tích dữ liệu

Đánh giá: Tập dữ liệu bị mất cân bằng lớn

Chỉ có 6.5% tỉ lệ mắc bệnh trong hơn 5000 người

Tỷ lệ bị tiểu đường trong dữ liệu



Tiền xử lý dữ liệu

- Xử lý giá trị thiếu

SimpleImputer: là một bộ xử lý giá trị thiếu trong thư viện scikit-learn, dùng để tự động thay thế các giá trị bị thiếu trong dữ liệu bằng một giá trị mà ta quy định (mean, median, mode...). hoặc xóa luôn dữ liệu thiếu

- Xử lý dữ liệu categorical

Là kỹ thuật trong học máy để chuyển đổi các biến phân loại (categorical) thành dạng số nguyên (numerical)

- Feature Scalling

Standardization: là kỹ thuật đưa các đặc trưng (features) về cùng một thang đo, bằng cách biến đổi chúng sao cho giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1

Với công thức:

$$z = \frac{x - \mu}{\sigma}$$

Tiền xử mất cân bằng dữ liệu

SMOTE (Synthetic Minority Oversampling Technique) là kỹ thuật tăng số lượng mẫu của lớp thiểu số bằng cách tạo ra dữ liệu tổng hợp (synthetic)

$$x_{\text{new}} = x_{\text{origin}} + \lambda(x_{\text{neighbor}} - x_{\text{origin}})$$

với λ là số ngẫu nhiên từ $0 \rightarrow 1$.

→ Dữ liệu mới có ý nghĩa không bị lặp lại

—

Đánh giá mô hình

	accuracy	precision	recall	f1	roc_auc
modelname					
Logistic	0.8121	0.2189	0.7612	0.3400	0.8734
Random Forest	0.9051	0.3103	0.4030	0.3506	0.8600

—

Demo chương trình

The End

THANK YOU FOR LISTENING